

Lista 5

Analiza szeregów czasowych zadanie 3

Kacper Szmigielski (282255)

Spis treści

1	Zadanie 3	2
1.1	a)	2
1.1.1	Definicje teoretyczne potrzebne do tego zadania	2
1.1.2	Reguła graficznej identyfikacji białego szumu	5
1.1.3	Formalne testy białoszumowości oparte na ACF	5
1.2	b)	9
1.2.1	Porównywanie testów graficznych oraz formalnych dla testowania białoszumowości	9

Spis rysunków

Spis tabel

1	Wyniki procentowe kwalifikacji danych jako biały szum	11
2	Wyniki procentowe kwalifikacji danych jako biały szum	11
3	Wyniki procentowe kwalifikacji danych jako biały szum	11

1 Zadanie 3

1.1 a)

1.1.1 Definicje teoretyczne potrzebne do tego zadania

Definicja 1 (Biały szum). *Proces losowy $\{X_t\}_{t \in \mathbb{Z}}$ nazywamy białym szumem, jeśli spełnia następujące warunki:*

1. $E[X_t] = \mu$ (stała średnia, zwykle przyjmuje się 0, bo zawsze można dane wycentrować),
2. $\text{Var}(X_t) = \sigma^2 < \infty$ (stała wariancja),
3. X_t i X_s są nieskorelowane dla $t \neq s$, tzn.

$$\text{Cov}(X_t, X_s) = 0 \quad \text{dla wszystkich } t \neq s.$$

Jeśli dodatkowo zmienne X_t są wzajemnie niezależne i mają rozkład normalny $\mathcal{N}(0, \sigma^2)$, to proces nazywamy gaussowskim białym szumem.

Definicja 2 (Szereg stacjonarny). *Szereg czasowy $\{X_t : t \in \mathbb{Z}\}$ nazywamy (słabo) stacjonarnym, jeśli dla dowolnych $t, r, s \in \mathbb{Z}$ spełnione są następujące warunki:*

1. $E[X_t^2] < \infty$,

2. średnia jest stała:

$$\mu_X(t) = E[X_t] = \mu = \text{const},$$

3. kowariancja zależy wyłącznie od przesunięcia czasowego:

$$\gamma_X(r, s) = \gamma_X(r + t, s + t),$$

to znaczy zależy tylko od różnicy $r - s$.

Definicja 3 (Estymator wartości średniej). *Niech x_1, x_2, \dots, x_n będzie realizacją szeregu czasowego $\{X_t\}$. Estymator wartości średniej μ_X definiujemy jako*

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t.$$

```
mn <- function(data){
  return (mean(data))
}
```

Definicja 4 (Próbkowa funkcja autokowariancji). *Niech x_1, x_2, \dots, x_n będzie realizacją szeregu czasowego. Próbkową funkcję autokowariancji dla opóźnienia h , gdzie $-n < h < n$, definiujemy jako*

$$\hat{\gamma}(h) = \frac{1}{n} \sum_{t=1}^{n-|h|} (x_{t+|h|} - \bar{x})(x_t - \bar{x}),$$

gdzie $\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t$ jest średnią próbkową.

```
ACVF <- function(data, h){
  x_bar = mn(data)
  result = 0
  n = length(data)
  if( abs(h) > n){
    stop("h must be greater than -n and lower than n")
  }
  for (t in 1:(n-abs(h))){
    result = result + (data[t + abs(h)] - x_bar) * (data[t] - x_bar)
  }
  result = result / n
  return (result)
}
```

Definicja 5 (Próbkowa funkcja autokorelacji). Niech x_1, x_2, \dots, x_n będzie realizacją szeregu czasowego, a $\hat{\gamma}(h)$ niech oznacza próbkową funkcję autokowariancji. Próbkową funkcję autokorelacji dla opóźnienia h , gdzie $-n < h < n$, definiujemy jako

$$\hat{\rho}(h) = \frac{\hat{\gamma}(h)}{\hat{\gamma}(0)}.$$

```
ACF <- function(data,h){
  n = length(data)

  if( abs(h) > n){
    stop("h must be greater than -n and lower than n")
  }

  part1 = ACVF(data,h)

  part2 = ACVF(data,0)

  result = part1/part2

  return (result)
}
```

Definicja 6 (Własności asymptotyczne estymatorów średniej, autokowariancji i autokorelacji). Niech $\{X_t\}$ będzie procesem stacjonarnym. Własności drugiego rzędu tego procesu są całkowicie określone przez średnią μ oraz funkcję autokowariancji $\gamma(\cdot)$.

Estymacja parametrów μ , $\gamma(\cdot)$ oraz funkcji autokorelacji

$$\theta(h) = \frac{\gamma(h)}{\gamma(0)},$$

na podstawie obserwacji X_1, X_2, \dots, X_n odgrywa zasadniczą rolę w metodach wnioskowania statystycznego, w szczególności przy doborze modelu oraz konstrukcji optymalnych prognoz.

Dlatego też istotne jest, aby stosowane estymatory $\hat{\mu}$, $\hat{\gamma}(h)$ oraz $\hat{\theta}(h)$ posiadały odpowiednie własności asymptotyczne, takie jak zgodność, asymptotyczna nieobciążoność oraz asymptotyczna normalność, zapewniające wiarygodność wnioskowania przy rosnącej liczbie obserwacji.

1.1.2 Reguła graficznej identyfikacji białego szumu

Szereg możemy uznać za realizację białego szumu jeżeli:

1. Co najmniej 95% autokorelacji próbkowych ($ACF(h), h = 1, 2, \dots, h_{max}$) znajduje się w przedziale ufności : $\frac{\pm 1,96}{\sqrt{n}}$
2. Nie powinno być autokorelacji “istotnie” wychodzących poza przedziały ufności $\frac{\pm 1,96}{\sqrt{n}}$

1.1.3 Formalne testy białośumowości oparte na ACF

1. Podstawowe testy oparte na ACF
 - a) test Boxa-Pierce’a
 - b) test Ljung-Boxa
2. Idea obu testów jest następująca: zamiast sprawdzać (tak jak w graficznym teście białośumowości) dla każdego $h = 1, 2, 3, \dots$ czy autokorelacja próbkowa $ACF(h)$ znajduje się pomiędzy przedziałami istotności $\frac{\pm 1,96}{\sqrt{n}}$, analizujemy pojedynczą wartość, tzn. statystykę testową opartą na ACF dla kilku/ kilkunastu początkowych opóźnień

1.1.3.1 Test Boxa-Pierce’a W jego przypadku postać statystyki testowej można wyrazić jako : $Q_{BP} = n \sum_{j=1}^h \hat{p}^2(j)$ gdzie h ozn. pewne maksymalne opóźnienie, a $\hat{p}(j)$ to próbkowa autokorelacja dla opóźnienia j .

Duża wartość Q_{BP} oznacza, że wartości ACF są zbyt duże, aby uznać dane za realizację ciągu nieskorelowanego (białego szumu)

Wiadomo, że jeżeli X_1, X_2, \dots, X_n jest realizacją ciągu iid o skończonej wariancji, wówczas Q_{BP} ma w przybliżeniu rozkład chi-kwadrat z h stopniami swobody

Uzasadnienie : przy tych założeniach $\sqrt{n}\hat{\theta}_j, j = 1, \dots, h$ są w przybliżeniu niezależnymi zm. losowymi o rozkładzie $N(0,1)$. Statystyka Q_{BP} jest więc sumą kwadratów h niezależnych zm. losowych o rozkładzie $N(0,1)$

W praktyce aby stwierdzić, czy wartość statystyki Q_{BP} jest zbyt duża wykorzystujemy wskaźnik p-value dla ustalonego poziomu istotności (zazwyczaj: $\alpha = 0.05$)

Zbyt mała p-wartość przemawia, przeciwko przypuszczeniu o losowości (jeżeli $p\text{-value} < 0.05$ to odrzucamy hipotezę o niezależności)


1.1.3.2 Test Ljungi-Boxa W przypadku Kjungi-Boxa (L-B) statystykę testową Q_{BP} zastępujemy przez

$$Q_{LB} = n(n+2) \sum_{j=1}^h \frac{\hat{p}^2(j)}{n-j}$$

Rozkład tego testu, jest lepiej przybliżony rozkładem granicznym od testu Boxa-Pierce'a i dlatego jest preferowany w praktyce

Oba powyższe testy zaimplementowane są w bibliotece `Box.test()`, będziemy z niej korzystać w tym sprawozdaniu

1.1.3.3 Zilustrowanie działania testów dla danych ($n = 200$) typu biały szum (rozkład $WN(0, \sigma^2)$) Prezentacja metody graficznej :



Test graficzny opiera się na wygenerowaniu wykresu funkcji ACF, oraz sprawdzenia, czy 95% autokorelacji próbkowych znajduje się w przedziale ufności dla $\alpha = 0.05$.

Oraz nie ma obserwacji istotnie wychodzących poza przedziały ufności

Na wykresie przedział ufności zaznaczony jest czerwonymi przerywanymi liniami

98% autokorelacji leży w przedziale ufności, i nie ma żadnych przypadków znacznie odsta-
jących

Teraz zastosujemy testy formalne dla wygenerowanych danych

Test Boxa-Pierce'a dla przedstawionych danych zwraca wartość

```
## [1] TRUE
```


Według testu przedstawione dane są białym szumem

Test Ljunga-Boxa dla danych testowych zwraca wartość

```
## [1] TRUE
```

Według testu Ljunga-Boxa przedstawione dane są białym szumem

1.1.3.4 Zilustrowanie działania testów dla danych ($n = 200$) typu (rozkład $Exp(2)$)



94% autokorelacji leży w przedziale ufności, plus pojawiają się informacje odstające, według testu graficznego nie jest to biały szum

Pomimo faktu, że z definicji jest to biały szum o średniej $\frac{1}{2}$ i wariancji $\frac{1}{4}$

Teraz zastosujemy testy formalne dla wygenerowanych danych

Test Boxa-Pierce'a dla przedstawionych danych zwraca wartość


```
## [1] TRUE
```

Według testu przedstawione dane są białym szumem
Test Ljunga-Boxa dla danych testowych zwraca wartość

```
## [1] TRUE
```

Według testu przedstawione dane są białym szumem

1.1.3.5 Zilustrowanie działania testów dla danych ($n = 200$) z autokorelacją (nie biały szum)



36% autokorelacji leży w przedziale ufności, więc według testu graficznego to nie jest biały szum

Test Boxa-Pierce'a dla przedstawionych danych zwraca wartość

```
## [1] FALSE
```

Według testu przedstawione dane nie są białym szumem

Test Ljunga-Boxa dla danych testowych zwraca wartość

```
## [1] FALSE
```

Według testu przedstawione dane nie są białym szumem

1.2 b)

1.2.1 Porównywanie testów graficznych oraz formalnych dla testowania białoszumowości

Definicja 7 (Zautomatyzowany test graficzny ACF dla białego szumu). Niech $\{X_t\}_{t=1}^n$ będzie szeregiem czasowym, a $\hat{\rho}(k)$ jego empiryczną funkcją autokorelacji

$$\hat{\rho}(k), \quad k = 0, 1, \dots, L,$$

gdzie L oznacza maksymalny analizowany lag (bez zera).

Chcemy zweryfikować hipotezę

$$H_0 : \{X_t\} \text{ jest białym szumem.}$$

(1) Przybliżony rozkład ACF i przedział ufności. Dla białego szumu przyjmujemy przybliżenie

$$\hat{\rho}(k) \approx \mathcal{N}\left(0, \frac{1}{n}\right),$$

co prowadzi do 95% przedziału ufności

$$CI = \left[-\frac{1.96}{\sqrt{n}}, \frac{1.96}{\sqrt{n}} \right].$$

(2) Liczba lagów wychodzących poza przedział ufności. Dla każdego laga $k = 1, \dots, L$ definiujemy zmienną wskaźnikową

$$I_k = \begin{cases} 1, & \text{gdy } |\hat{\rho}(k)| > \frac{1.96}{\sqrt{n}}, \\ 0, & \text{w przeciwnym razie.} \end{cases}$$

Liczbę lagów wychodzących poza przedział ufności opisujemy zmienną

$$X = \sum_{k=1}^L I_k.$$

Przyjmujemy przybliżony model

$$X \sim \text{Bin}(L, 0.05),$$

co odpowiada założeniu, że pojedyncza autokorelacja ma prawdopodobieństwo ok. 5% wyjścia poza 95% przedział ufności.

Niech $x_{0.95}$ będzie 95-tym percentylem rozkładu $\text{Bin}(L, 0.05)$, tzn.

$$P(X \leq x_{0.95}) = 0.95.$$

(3) Znacznie odstające autokorelacje. Wprowadzamy dodatkowo pojęcie znacznie odstającej autokorelacji: lag k uznajemy za znacznie odstający, jeśli

$$|\hat{\rho}(k)| > c \cdot \frac{1.96}{\sqrt{n}},$$

gdzie $c > 1$ jest stałą ustaloną heurystycznie; w praktyce przyjmujemy $c = 1.7$.

(4) Reguła decyzyjna zautomatyzowanego testu graficznego ACF.

Na podstawie powyższych elementów definiujemy zautomatyzowany test graficzny ACF:

- **Akceptujemy** hipotezę H_0 („szereg jest zgodny z białym szumem”), jeśli spełnione są oba warunki:

1. $X \leq x_{0.95}$, tzn. co najmniej 95% autokorelacji leży w przedziale ufności,
2. nie występuje żadna znacznie odstająca autokorelacja, tzn.

$$|\hat{\rho}(k)| \leq 1.7 \cdot \frac{1.96}{\sqrt{n}} \quad \text{dla każdego } k = 1, \dots, L.$$

- **Odrzucamy** hipotezę H_0 , jeśli:

1. $X > x_{0.95}$ (zbyt wiele lagów wychodzi poza przedział ufności) lub
2. istnieje lag k taki, że

$$|\hat{\rho}(k)| > 1.7 \cdot \frac{1.96}{\sqrt{n}},$$

co interpretujemy jako obecność znacznie odstającej autokorelacji.

Test ten stanowi formalizację klasycznego „testu graficznego” ACF: wymaga, aby zdecydowana większość słupków autokorelacji mieściła się w przedziale ufności oraz aby nie występowały pojedyncze, bardzo duże piki, które wskazywałyby na istotną autokorelację.

W testach przyjmujemy $\alpha = 0.05$

1.2.1.1 Porównanie pod względem liczby powtórzeń

1.2.1.1.1 Dla $WN(0, \sigma^2)$

##	graficzny_test	test_pearsona	test_ljunga
## 1	0.924	0.954	0.95
## 2	0.925	0.945	0.94
## 3	0.860	0.960	0.96
## 4	0.920	1.000	1.00
## 5	1.000	1.000	1.00

Tabela 1: Wyniki procentowe kwalifikacji danych jako biały szum

	500	200	50	25	5
graficzny_test	0.92	0.92	0.86	0.92	1
test_pearsona	0.95	0.94	0.96	1.00	1
test_ljunga	0.95	0.94	0.96	1.00	1

1.2.1.1.2 Dla #Exp(4)

##	graficzny_test	test_pearsona	test_ljunga
## 1	0.908	0.96	0.958
## 2	0.910	0.95	0.950
## 3	0.840	0.96	0.960
## 4	0.880	1.00	1.000
## 5	1.000	1.00	1.000

Tabela 2: Wyniki procentowe kwalifikacji danych jako biały szum

	500	200	50	25	5
graficzny_test	0.91	0.91	0.84	0.88	1
test_pearsona	0.96	0.95	0.96	1.00	1
test_ljunga	0.96	0.95	0.96	1.00	1

1.2.1.1.3 Dla danych skorelowanych

##	graficzny_test	test_pearsona	test_ljunga
## 1	0	0	0
## 2	0	0	0
## 3	0	0	0
## 4	0	0	0
## 5	0	0	0

Tabela 3: Wyniki procentowe kwalifikacji danych jako biały szum

	500	200	50	25	5
graficzny_test	0	0	0	0	0
test_pearsona	0	0	0	0	0

	500	200	50	25	5
test_ljunga	0	0	0	0	0